

Sistema Inteligente de Triagem em Pronto-Socorro



UNIVERSIDADE FEDERAL DO CEARÁ

Inteligência Artificial [CK0248]

2026.1

Prof. : JOSE ANTONIO FERNANDES DE MACEDO

EQUIPE

JOÃO GABRIEL AQUINO FERREIRA - 582424

ROMULO EMANUEL MARINHO BARBOSA - 579586

GABRIEL GARCIA COLARES - 581964

1.Introdução e Motivação do Problema

Os pronto-socorros brasileiros enfrentam um cenário de superlotação diária, o que torna a gestão do fluxo de pacientes um desafio crítico para a saúde pública. O modelo tradicional de triagem manual, no qual um profissional avalia cada indivíduo no momento da chegada, apresenta limitações estruturais severas: além de ser um processo lento e sujeito a erros humanos, trata-se de um método estático. Ou seja, essa abordagem falha ao não contabilizar como o estado clínico do paciente pode se agravar enquanto ele permanece na fila de espera.

A deterioração clínica ocorre exatamente quando o quadro de saúde de um indivíduo piora ativamente a cada unidade de tempo em que aguarda sem intervenção. Para mitigar este problema, este trabalho propõe o desenvolvimento de um sistema inteligente de triagem em pronto-socorro. A solução integra dois subproblemas complementares por meio de técnicas de Inteligência Artificial.

Primeiramente, utiliza-se a modelagem estatística, por meio de uma Rede Bayesiana, para estimar a probabilidade de gravidade de cada paciente com base em seus sintomas e sinais vitais, uma técnica que lida naturalmente com a incerteza e a incompletude das avaliações iniciais. Em seguida, o sistema aplica um algoritmo de otimização heurística, o Algoritmo A*, para decidir a melhor ordem de atendimento. Essa decisão não baseia-se apenas na gravidade imediata, mas na minimização do dano total causado pela espera, calculando o risco de deterioração acumulado da fila.

Dessa forma, a união entre o raciocínio probabilístico e a otimização matemática transcende o processamento de dados brutos, atuando como uma ferramenta de intervenção ativa. Ao priorizar pacientes cujo risco clínico pode escalar exponencialmente no tempo, o sistema garante a alocação eficiente de recursos médicos, prevenindo o colapso clínico na sala de espera e, em última instância, protegendo vidas.

2.Modelagem da rede bayesiana

A aplicação de Redes Bayesianas na triagem médica justifica-se pela sua capacidade matemática de modelar relações de causa e efeito, lidando de forma robusta com a incerteza e com as informações frequentemente incompletas do ambiente hospitalar de emergência.

Para a estruturação do grafo probabilístico, o modelo foi desenhado com seis variáveis observáveis atuando como nós pais (causas): Febre, Saturação de O₂, Pressão Arterial, Frequência Cardíaca, Nível de Dor e Idade somada à presença de Doença Crônica. Toda a rede converge as evidências para um único nó de saída (efeito), a variável alvo "Gravidade", que classifica o risco do paciente em três estados: Baixa, Média e Alta.

Cabe destacar que a validação de um modelo probabilístico exige um volume expressivo de dados consistentes. Diante da indisponibilidade de bases de dados hospitalares abertas, optou-se pela geração de uma base sintética contendo 1.000 registros de pacientes. Para atestar a viabilidade estatística e clínica desta simulação, os dados não foram gerados de

forma arbitrariamente aleatória. A lógica de distribuição e a atribuição da variável alvo foram alicerçadas nos parâmetros do Protocolo de Manchester. Dessa forma, sintomas que representam deterioração vital imediata como saturação de oxigênio crítica e pressão arterial em estado de choque receberam pesos matemáticos maiores do que queixas de dor leve, resultando em uma distribuição realista onde apenas a minoria dos casos é classificada como gravidade altíssima.

Nesta lógica, os sintomas que representam uma ameaça imediata à vida receberam os maiores pesos: uma Saturação de O₂ em estado "Crítico" adicionou 3 pontos ao paciente, enquanto um quadro de "Pressão Anormal/Choque" adicionou 2 pontos. Variáveis que indicam urgência, mas sem risco de colapso instantâneo como "Dor Intensa", "Febre Alta", "Frequência Cardíaca Alterada" e "Idoso/Comorbidade", receberam 1 ponto cada. A variável alvo foi definida de forma determinística por este somatório: casos com 4 pontos ou mais foram rotulados como Gravidade Alta, entre 2 e 3 pontos como Gravidade Média, e pontuações inferiores como Gravidade Baixa.

Com a base estruturada, o preenchimento das Tabelas de Probabilidade Condicional (CPTs) evitou a inserção manual de valores, o que poderia introduzir vieses subjetivos. Empregou-se a biblioteca estatística *pgmpy* para realizar o aprendizado de máquina paramétrico. Utilizando o método *fit()*, a rede bayesiana aprendeu as CPTs lendo as frequências e correlações diretamente da base simulada. O motor de inferência resultante (*Variable Elimination*) provou-se capaz de traduzir qualquer ficha de sinais vitais em um vetor probabilístico exato, entregando o insumo central exigido pelo algoritmo de busca no Módulo subsequente.

3. Formulação do problema de busca

O Módulo de Otimização de Atendimento foi formulado como um problema de busca em espaço de estados, onde o objetivo é encontrar a sequência de atendimentos que minimizem o sofrimento coletivo de deterioração clínica na fila de espera. Em vez de utilizar abordagens ingênuas (lineares) que falham em representar o colapso biológico ao longo do tempo, o sistema modela o comportamento da fila através de uma Função de Risco Exponencial:

$$R_i(t) = P(alta) \times e^{\frac{t}{\tau}}$$

Onde:

- $P(alta)$: É a probabilidade de o paciente apresentar um quadro crítico, extraída diretamente da inferência da Rede Bayesiana do Módulo 1.
- t : É o tempo cumulativo (em minutos) que o paciente já passou aguardando no pronto-socorro.
- τ : É a constante de tolerância clínica, fixada em 30 minutos, que regula a velocidade de agravamento do risco. O uso da base de Euler (e) espelha com precisão a deterioração biológica contínua, fazendo com que o perigo de um paciente aumente de forma agressiva à medida que ele é negligenciado pelo tempo.

3.1 Componentes Formais do Espaço de Estados

Para que o algoritmo A* pudesse navegar sistematicamente pelas configurações de atendimento, a estrutura foi formalizada nos seguintes componentes:

3.1.1 Estado (n): Representado no código pela classe *EstadoFila*. É composto por um conjunto de objetos do tipo *Paciente* que ainda aguardam atendimento, o histórico da *ordem_atendimento* já consolidada, o custo acumulado até o momento (*custo_g*) e o marcador de *tempo_atual* do hospital.

3.1.2 Estado Inicial: A configuração da recepção no tempo zero, contendo todos os pacientes que passaram pela triagem com seus respectivos tempos de espera iniciais e nenhuma ação tomada.

3.1.3 Ações e Transições: A ação consiste em selecionar exatamente um paciente da lista de restantes para ser atendido, removendo-o da fila. Cada ação consome um intervalo fixo de $\Delta t = 10$ minutos, atualizando o relógio do hospital e somando 10 minutos ao tempo de espera de todos os indivíduos que permaneceram na retaguarda.

3.1.4 Teste de Objetivo: O algoritmo atinge o estado meta (*Goal Test*) quando a lista de pacientes restantes está completamente vazia (*not self.pacientes_restantes*), indicando que todo o fluxo de pronto-socorro foi escoado com sucesso.

3.2 Funções de Custo e Heurística Admissível

O percurso do algoritmo é guiado pela função de avaliação $f(n) = g(n) + h(n)$, onde cada componente desempenha um papel crucial para garantir a eficiência e a otimalidade da busca:

3.2.1 Custo Real ($g(n)$): O custo de transição entre estados é o "dano colateral" gerado pela escolha de atendimento. Matematicamente, o custo de uma ação é definido pela soma dos riscos atuais de todos os pacientes que continuam esperando na fila enquanto o paciente escolhido está sendo atendido. O *novo_custo_g* acumula esse impacto ao longo do tempo.

3.2.2 Função Heurística ($h(n)$): Implementada através do método *heuristica_h*, calcula a soma instantânea dos riscos de deterioração dos pacientes restantes na configuração atual. Esta heurística é admissível porque ela assume, hipoteticamente, que todos os pacientes restantes poderiam ser atendidos em paralelo no tempo atual, sem sofrer o incremento futuro de novos atrasos. Como ela nunca superestima o custo real de atendimento (que será obrigatoriamente maior devido ao avanço do relógio de 10 em 10 minutos), o critério de otimalidade do A* é preservado, garantindo que a sequência de menor risco global seja encontrada.

4. Integração entre os módulos

A eficácia de um sistema de Inteligência Artificial aplicado a cenários reais não reside apenas na complexidade matemática de seus modelos isolados, mas na fluidez automatizada com que os dados transitam entre eles. Para garantir essa coesão, o sistema foi desenhado sob o princípio da modularidade, estabelecendo um *pipeline* de integração contínua (através da função *receber_paciente*) que conecta a inferência probabilística do Módulo 1 ao motor de busca heurística do Módulo 2.

O fluxo de processamento de dados ocorre em quatro etapas sequenciais e automatizadas, sem a necessidade de intervenção humana na transição das informações:

4.1 Leitura da Ficha de Triage (Entrada de Dados): O processo inicia-se na simulação da porta de entrada do hospital. Os sinais vitais e as informações do paciente, coletados pelo profissional de triagem, são formatados em uma estrutura de dicionário de dados (ex: $\{ 'SaturacaoO2': 'Reduzida', 'Febre': 'Alta' \}$).

4.2 Processamento pelo Motor Bayesiano: Este dicionário é injetado diretamente como evidência (*evidence*) no motor de inferência da Rede Bayesiana (*Variable Elimination*). A rede cruza essas evidências com as Tabelas de Probabilidade Condicional (CPTs) previamente treinadas e calcula a distribuição de probabilidade do estado clínico daquele indivíduo.

4.3 Tradução Algorítmica (Extração): Em vez de repassar um relatório complexo, o *pipeline* atua como um filtro. O código isola o valor escalar correspondente unicamente à probabilidade de Gravidade Alta denotado como $P(alta)$.

4.4 Transformação em Objeto Consumível (Saída para o Módulo 2): É nesse momento que a modelagem estatística se converte no insumo para a teoria dos grafos. O valor de $P(alta)$ é utilizado como parâmetro genético para instanciar o objeto computacional da classe *Paciente*. O novo paciente, agora encapsulado com sua identidade, seu tempo de espera atual e seu fator de risco bayesiano, é anexado à fila dinâmica do hospital.

Dessa forma, a estrutura de dados é entregue perfeitamente formatada ao espaço de estados do algoritmo A*. O motor de fila pode então iterar sobre esses objetos iteráveis, consumindo a probabilidade $P(alta)$ para calcular a curva de deterioração exponencial $R_i(t) = P(alta) \times e^{-\frac{t}{\tau}}$ e definir a rota ótima de atendimentos.

5.Experimentos e resultados

Para validar a eficácia da modelagem matemática na gestão do fluxo hospitalar, o sistema foi submetido a simulações comparando três abordagens de decisão: FIFO (Ordem de Chegada), Estratégia Gulosa (atendimento restrito à gravidade clínica isolada) e o algoritmo A*(busca heurística global). A métrica de avaliação utilizada foi o Risco Total Acumulado.


5.1 Cenário Simples (5 Pacientes) e a Otimalidade do A*

No primeiro experimento, uma fila controlada de 5 pacientes foi processada. O cenário testou a vulnerabilidade da tomada de decisão ao inserir discrepâncias de tempo de espera prévio. Os resultados evidenciaram a superioridade do espaço de busca:

5.1.1 Custo FIFO: 10.55

5.1.2 Custo Gulosa: 7.92

5.1.3 Custo A* (Rota Ótima): 6.90




A estratégia Gulosa superou o FIFO por mitigar os quadros clinicamente mais críticos logo no início. No entanto, o algoritmo A* obteve o menor custo global absoluto, explorando a árvore de estados com máxima eficiência (apenas 7 nós visitados). A Gulosa falhou em encontrar o trajeto ótimo porque ela avalia apenas o fator $P(alta)$ presente, ignorando pacientes com gravidade moderada que já acumulavam tempos de espera perigosos. O A*, por calcular a função de custo $f(n)$, encontrou o equilíbrio perfeito, antecipando o momento exato em que a deterioração de um paciente leve ultrapassa a de um paciente recém-chegado.

5.2 Cenário Médio (25 Pacientes) e a Barreira da Escalabilidade

O segundo experimento simulou uma fila realista de 25 pacientes. Conforme esperado pela teoria dos grafos, a busca exata através do A* puro atingiu sua barreira de viabilidade computacional devido à explosão combinatória, visto que o ordenamento perfeito de 25 nós demanda o cálculo de 25! permutações. Isso restringe a comparação computacional rápida às abordagens FIFO e Gulosa, revelando a discrepância em grande escala:

5.2.1 Custo Gulosa: 2854.06

5.2.2 Custo FIFO: 14646.26



Neste cenário de estresse, a Estratégia Gulosa demonstrou uma superioridade esmagadora sobre o modelo tradicional de portas de hospital (FIFO). Ao ordenar a fila de forma decrescente pela probabilidade de gravidade, a Gulosa neutralizou os multiplicadores base mais altos, impedindo que os casos severos fossem amplificados pela função $R_i(t) = P(alta) \times e^{\frac{t}{\tau}}$ no fundo da fila. O FIFO colapsou justamente por ser agnóstico aos dados clínicos, submetendo pacientes com alto risco primário a esperas letais.

5.3 Conclusão da Dinâmica de Otimização

Os experimentos corroboram que sistemas passivos (FIFO) geram danos exponenciais à saúde coletiva e que avaliações puramente clínicas (Gulosas), embora muito superiores, falham em não prever a deterioração biológica. Conclui-se que a gestão de filas hospitalares deve transcender regras estáticas, exigindo algoritmos heurísticos capazes de ponderar a relação inseparável entre gravidade clínica e tempo de espera.

6. Epílogo

A implementação deste sistema inteligente para a triagem hospitalar permitiu testar, na prática, o comportamento de algoritmos clássicos diante de um problema crítico de saúde pública. A análise final do projeto revela *insights* metodológicos cruciais sobre a aplicação da IA na gestão de fluxo de pacientes.

6.1 O que funcionou: A união entre Probabilidade e Busca

O maior êxito do projeto foi a validação do *pipeline* contínuo entre a modelagem probabilística e a teoria dos grafos. A Rede Bayesiana (Módulo 1) provou ser a ferramenta ideal para lidar com a incerteza dos sinais vitais, extraíndo o fator de risco clínico real (P). Simultaneamente, o Algoritmo A* (Módulo 2) foi capaz de consumir esse dado e transformá-lo em uma função de custo temporal ($P \times e^{\frac{t}{\tau}}$). Essa arquitetura funcionou com perfeição no cenário controlado (5 pacientes), onde o A* encontrou a rota matematicamente ótima, provando que é possível ensinar uma máquina a ponderar dinamicamente a gravidade de um paciente contra o seu tempo de espera, prevenindo o colapso clínico na recepção.

6.2 O que não funcionou: A Barreira do Hardware e a Explosão Combinatória

A principal falha da abordagem proposta reside na sua escalabilidade para cenários reais de grande volume. Ao aplicar o algoritmo A* puro no cenário médio (25 pacientes), o sistema colidiu violentamente contra uma barreira de hardware. O problema central da busca exata em grafos dinâmicos é a chamada explosão combinatória. Para encontrar a rota absolutamente ótima, o algoritmo precisa processar $25!$ permutações de fila, um número na casa dos septilhões (10^{25}). Isso satura rapidamente a memória RAM e o poder de processamento de qualquer computador convencional, tornando a tomada de decisão em tempo real inviável para um pronto-socorro lotado.

6.3 O que poderia ser melhorado e Aprendizados Finais

Para transpor essa limitação computacional em trabalhos futuros, a arquitetura do motor de fila precisaria ser adaptada. Em vez de uma busca exaustiva, o sistema poderia implementar algoritmos de Busca Local, como *Simulated Annealing*, *Hill Climbing* ou Algoritmos Genéticos. Essas abordagens abdicam da garantia matemática de encontrar a rota 100% perfeita em troca de encontrar uma rota "excelente" em frações de segundo, um trade-off perfeitamente aceitável e necessário na engenharia de software aplicada ao mundo real.

Como aprendizado final, o projeto demonstra que unir a estatística (Redes Bayesianas) a algoritmos de roteamento (Busca Clássica) muda o paradigma da Ciência de Dados na saúde. A inteligência artificial deixa de ser uma mera ferramenta passiva de "classificação de diagnóstico" para se tornar um agente ativo de intervenção e logística, gerando valor real para a sociedade ao garantir que o recurso médico chegue a quem precisa antes que o agravamento biológico se torne irreversível.